

多变量比较方法 (Marascuilo)
计算每一对总体的样本比例之差的绝对值
临界值: $CV_{ij} = \sqrt{\chi^2_{\alpha} \times \frac{P_i(1-P_i) + P_j(1-P_j)}{n_j}}$
 X^2 : 显著性 α , 自由度 $k-1$ ($m-1$)
若 $|P_i - P_j| > CV_{ij}$, 则显著

STEP1: P_i = 复数比例 最大的 i, j 一样
STEP2: $|P_i - P_j|$ 计算 & CV_{ij} 比较
④ 独立性检验

a. H_0 : 事件 AB 独立 H_a : 不独立
b. 对于 r 行 c 列, 服从自由度为 $(n-1) \times (c-1)$ 的 X^2 分布
 $X^2 = \sum \sum \frac{(f_{ij} - e_{ij})^2}{e_{ij}} \sim \chi^2_{(m-1)(n-1)}$

eg. Education & Income.
Uni HS None Total
Wealthy 20 15 10 45
Middle 40 25 20 85
Poor 8 14 23 45
Total 68 54 53 175

⑤ 拟合优度 数据分布是否服从预期
① 为独立分布: 一次 trial 中, k 个结果且
概率 $p_1, \dots, p_k$ ($\sum p_i = 1$)
n 次 trial, 第 i 个结果出现次数 ($\sum X_i = n$)
则 $(X_1, X_2, \dots, X_k) \sim$ 多项分布, 每个 X_i 服从
eg. market share 是在同系列产品中
原先 A: 3%, B: 6%, C: 20%
现在: A: 48 B: 98 C: 14 Total: 200
 $\hat{p}_A = 200 \times 3\% = 6$
 H_0 : 总体服从多项分布
 H_a : 不服从
 $\chi^2 = \sum \frac{(f_i - e_i)^2}{e_i} \sim \chi^2_{(k-1)}$

② 正态分布 eg. 考试成绩 50 人
 $\Rightarrow \bar{X} = 68.4, S = 10.41$
 H_0 : 服从 $N(68.4, 10.41)$
 H_a : 不服从
把连续变量变为分量的不同类别
($e_i > 5$ 下, $\frac{1}{5} = 10$, 最多分 10 组)

eg. n C_n^k ($X_{EW}(k=0.05)$) $\alpha_{EW}(k=0.05)$
3 3 0.1424 0.0492
5 10 0.906 0.0489
10 45 0.906 0.0488
n 越大, α_{EW} 越大 越容易
缺: 误差大

③ ANOVA 3 个及以上总体均值相等
1. 样本均值是随机变量, 抽样随机性
样本误差来源:
① 组内: M_i 相等 $\Rightarrow$ 抽样误差 $\Rightarrow X_i$ 不同 S_{ij}
② 组间: M_i 存在差异 $\Rightarrow X_i$ 不同 $\alpha_j + \epsilon_{ij}$

2. $H_0: M_1 = M_2 = \dots = M_k = M$
 H_a : 不全相等
 $H_1: X_{ij} = M + \epsilon_{ij}$
 $H_a: X_{ij} = M_j + \epsilon_{ij} = M + (M_j - M) + \epsilon_{ij}$
3. ANOVA 假设: $X_{ij} \sim iid N(\mu, \sigma^2)$
① 每个总体正态
② 方差齐性: σ^2 相等但未知
③ 观测值相互独立

4. 构造 $\frac{\alpha_j + \epsilon_{ij}}{S_{ij}} \sim 1$, 组内误差 拒绝 H_0
b. 因于处理, 实验个体, 反应变量
因于处理如何影响反应变量
盒装 1.2 4 餐 打份

One-way ANOVA 具体均值 $\bar{X}$
① SST 组间: $SST = \sum_{j=1}^k n_j (\bar{X}_j - \bar{X})^2 = \sum_{j=1}^k n_j (\bar{X}_j - \bar{X})^2$
 $dft_{STR} = k-1$
 $MSTR = \frac{SSTR}{dft_{STR}}$
② 组内: $SSE = \sum_{j=1}^k (n_j - 1) S_j^2 = \sum_{j=1}^k \sum_{i=1}^{n_j} (X_{ij} - \bar{X}_j)^2$
 $dft_{SE} = N - k$
 $MSE = \frac{SSE}{dft_{SE}}$
③ 所有误差: $SST = \sum_{j=1}^k \sum_{i=1}^{n_j} (X_{ij} - \bar{X})^2 = \sum \sum (X_{ij} - \bar{X}_j + \bar{X}_j - \bar{X})^2$
 $dft = N - 1 \Rightarrow$ 拒绝 H_0
 $S^2 = \frac{SST}{dft}$
 $\therefore SST = SSE + SSTR$
 $dft = dft_{SE} + dft_{STR}$
④ $F = \frac{MSTR}{MSE} \sim F(k-1, N-k)$
 H_0 为真 $F \sim 1$, H_0 假 F 很大, 用 F_{α} 上界

ANOVA Table
Source of Variation Sum of Squares df Mean Square F F_{crit} P-value
Treatment SSTR k-1 MSTR MSR MSE F_{crit}
Error SSE N-k MSE
Total SST N-1 S²

⑤ 事后分析: 拒绝 H_0 后两两分析
13.3 Fisher 的 LSD 方法 最小显著性不同
 $H_0: \mu_i = \mu_j$ $H_a: \mu_i \neq \mu_j$
 $t = \frac{\bar{X}_i - \bar{X}_j}{\sqrt{MSE(\frac{1}{n_i} + \frac{1}{n_j})}} \sim t_{(N-k)}$
 $|X_i - X_j| > LSD$ 则拒绝 H_0
 $LSD = t_{\alpha/2}(N-k) \cdot \sqrt{MSE(\frac{1}{n_i} + \frac{1}{n_j})}$

⑥ Bonferroni adjustment
两两比较犯 I 类错误的概率:
 $1 - (1 - \alpha)^{C_n^2} = \alpha_{EW} = n \times \text{单次 I 类错误}$
修正: $\alpha' = \frac{\alpha_{EW}}{C_n^2} \Rightarrow$ 反回来求 α_{EW}
eg. n C_n^k ($X_{EW}(k=0.05)$) $\alpha_{EW}(k=0.05)$
3 3 0.1424 0.0492
5 10 0.906 0.0489
10 45 0.906 0.0488
n 越大, α_{EW} 越大 越容易
缺: 误差大

7. One-way ANOVA with Blocking
随机化区组设计: 有接受 H_0 反 H_0
消除系统性条件
消除: $\bar{X}$
b. ϵ_{ij} : b 个 blocking
 $X_{ij} = M + \alpha_j + \epsilon_{ij}$
 $= M + \alpha_j + \beta_i + \epsilon_{ij}$
a 每个格子至 1 个 ϵ_{ij}

① SST: $SST = \sum_{j=1}^k \sum_{i=1}^{n_j} (X_{ij} - \bar{X})^2 = \sum_{j=1}^k n_j (\bar{X}_j - \bar{X})^2$
 $dft_{STR} = k-1$
 $MSTR = \frac{SSTR}{dft_{STR}}$
② SSB: $SSB = \sum_{i=1}^b \sum_{j=1}^k (X_{ij} - \bar{X})^2 = \sum_{i=1}^b (X_i - \bar{X})^2$
 $dft_{SBL} = b-1$
 $MSBL = \frac{SSBL}{dft_{SBL}}$
③ SSE: $SSE = \sum_{i=1}^b \sum_{j=1}^k (X_{ij} - \bar{X}_i - \bar{X}_j + \bar{X})^2$
 $= SST - SSTR - SSB$
 $dft_{SE} = (k-1)(b-1)$
④ SST: $SST = \sum_{j=1}^k \sum_{i=1}^{n_j} (X_{ij} - \bar{X})^2$ $dft_{ST} = N-1$
 $dft_{ST} = dft_{STR} + dft_{SBL} + dft_{SE}$
 $F = \frac{MSTR}{MSE} \sim F(k-1, (k-1)(b-1))$
ANOVA Table 加一行 Block

8. 如果两个格子内多于 1 个, 但每行一样
5 个数据解耦 = 显著

① SST: 平方和为个人 $dft_{STR} = k-1$
② SSB: $SSB = \sum_{i=1}^b \sum_{j=1}^k (X_{ij} - \bar{X})^2$ $dft_{SBL} = b-1$
③ SST: $SST = \sum_{j=1}^k \sum_{i=1}^{n_j} (X_{ij} - \bar{X})^2$ $dft_{ST} = N-1$
④ SSE 组内 = $SST - SSTR - SSB$
 $dft_{SE} = dft_{ST} - dft_{STR} - dft_{SBL}$
9. 双因素因 A, B $\Rightarrow$ ab 种组合
主效应 & 交互
格子内 1 个
 $X_{ijk} = \mu + \alpha_j + \beta_i + (\alpha\beta)_{ij} + \epsilon_{ijk}$
k 是组合内重复次
A 行 B 列
 $X_{ijk} = \mu + \alpha_j + \beta_i + (\alpha\beta)_{ij} + \epsilon_{ijk}$
① SST: $SST = \sum \sum \sum (X_{ijk} - \bar{X})^2$ $dft = N-1$
② SSA: $SSA = \sum \sum (X_{ij} - \bar{X})^2 = b \sum (X_i - \bar{X})^2$
 $dft_{SA} = b-1 \Rightarrow MSA$
③ SSB: $SSB = \sum \sum (X_{ij} - \bar{X})^2 = a \sum (X_j - \bar{X})^2$
 $dft_{SB} = a-1$
④ SSAB: $SSAB = \sum \sum (X_{ij} - \bar{X}_i - \bar{X}_j + \bar{X})^2$
 $dft_{AB} = (a-1)(b-1)$
⑤ SSE: $SSE = \sum \sum \sum (X_{ijk} - \bar{X}_{ij} - \bar{X}_i - \bar{X}_j + \bar{X})^2$ $dft = n \cdot ab$
⑥ ANOVA Table
Source of Variation Sum of Squares df Mean Square F F_{crit} P-value
Factor A SSA a-1 MSA MSE MSA/MSE F_{crit}
Factor B SSB b-1 MSB MSE MSB/MSE F_{crit}
Interaction SSAB (a-1)(b-1) MSAB MSE MSAB/MSE F_{crit}
Error SSE n-ab MSE
Total SST n-ab-1

⑦ 看图
交互: 高高低低
A: 30 $\Rightarrow$ 2 A=22
B: Low 交互小
A: 20 $\Rightarrow$ 4 A=20
response
Low High
主: V 交互: X
主: V 交互: V

⑧ 回归分析
1. $y = \beta_0 + \beta_1 X_1 + \beta_2 X_2 + \dots + \beta_p X_p + \epsilon$
因变量 自变量
简单线性回归: $p=1$
多元线性回归: $p>1$
简单线性, X_1 与 交互
2. 假设
 $E(\epsilon) = 0 \Rightarrow E(y) = \beta_0 + \beta_1 E(X_1) + \dots + \beta_p E(X_p)$
 $\text{Var}(\epsilon) = \sigma^2 \Rightarrow \text{Var}(y) = \sigma^2$
 ϵ 独立且 $\sim N(0, \sigma^2)$
3. 最小二乘法: $\min \sum (y_i - \hat{y}_i)^2 = SSE$
 $y_i = \beta_0 + \beta_1 X_{i1} + \epsilon_i$ $i = 1 \dots n$
 $\hat{\beta} = \frac{\sum_{i=1}^n (X_i - \bar{X})(y_i - \bar{y})}{\sum_{i=1}^n (X_i - \bar{X})^2}$
 $\hat{\beta}_0 = \bar{y} - \hat{\beta}_1 \bar{X}$
 $\text{Var}(\hat{\beta}) = \frac{\text{Var}(y_i)}{\sum_{i=1}^n (X_i - \bar{X})^2}$
 $\text{Var}(\hat{\beta}_0) = \text{Var}(y_i) (\frac{1}{n} + \frac{\bar{X}^2}{\sum_{i=1}^n (X_i - \bar{X})^2})$
4. 多元线性回归
 $\hat{y} = X \hat{\beta}$
 $X = \begin{pmatrix} 1 & X_{11} & X_{12} & \dots & X_{1p} \\ \vdots & \vdots & \vdots & \ddots & \vdots \\ 1 & X_{n1} & X_{n2} & \dots & X_{np} \end{pmatrix} (n \times (p+1))$
 $y = \begin{pmatrix} y_1 \\ \vdots \\ y_n \end{pmatrix} \beta = \begin{pmatrix} \beta_0 \\ \beta_1 \\ \vdots \\ \beta_p \end{pmatrix} X_j = \begin{pmatrix} X_{1j} \\ \vdots \\ X_{nj} \end{pmatrix}$
 $\hat{\beta} = (X^T X)^{-1} X^T y$
 $\text{Var}(\hat{\beta}) = \text{Var}(y_i) \cdot (X^T X)^{-1}$
5. 数据解耦 = 显著

① 单个变量显著性: $H_0: \beta_i = 0$
 $t = \frac{\hat{\beta}_i - 0}{\text{se}(\hat{\beta}_i)} \sim N(0, 1)$
相同条件下比较 (2 个原则: 1.96-95%)
② F-test Joint $H_0: \beta_0 = \beta_1 = \dots = \beta_p = 0$
Significance: $H_a: \text{不全} = 0$
a. SST: $SST = \sum_{i=1}^n (y_i - \bar{y})^2$ $dft = n-1$
b. SSE: $SSE = \sum_{i=1}^n (y_i - \hat{y}_i)^2$ $dft = n-p-1$
c. SSR: $SSR = \sum_{i=1}^n (\hat{y}_i - \bar{y})^2$ $dft = p$
one-way ANOVA
Source Sum of Squares df Mean Square F
Regression SSR p MSR MSR/MSE
Error SSE n-p-1 MSE
Total SST n-1
 $F = \frac{MSR}{MSE} \sim F(p, n-p-1)$ 与 F_{α} 比较
b. 拟合优度: R^2 越大, 解释越好
① $R^2 = \frac{SSR}{SST} = 1 - \frac{SSE}{SST} \in [0, 1]$
② 调整 $R^2 = 1 - (1-R^2) \frac{n-1}{n-p-1} = 1 - \frac{SSE/(n-p-1)}{SST/(n-1)}$
7. 多重线性性:
① $|r_{X_1 X_2}| = \frac{\text{Cov}(X_1, X_2)}{\sigma_{X_1} \sigma_{X_2}} \geq 0.7$
② VIF: 方差膨胀因子
 $VIF_j = \frac{1}{1 - R_j^2} \geq 10$ $R_j^2 = 0.9$ 则 $VIF_j = 10$
③ 解决: 去除一个
8. 波动大 $\Rightarrow$ 对数据/比例做处理
非线性 $y = \beta_0 X_1^2 + \log y = \log \beta_0 + \beta_1 \log X_1$
9. 高次 & 交互 $\Rightarrow \beta_{ij} \neq 0$ 互补促进
且此时 $\frac{\partial y}{\partial \beta_i} = f(X_1, X_2) \rightarrow$ 取决于 X_j
10. 哑变量: $X_2 = 0$, 故障
① X_1 变量, X_2 哑变量
 $y = \beta_0 + \beta_1 X_1 + \beta_2 X_2 + \epsilon$
 $E(y | X_2 = 0) = \beta_0 + \beta_1 X_1$
 $E(y | X_2 = 1) = \beta_0 + \beta_1 X_1 + \beta_2$
相对于基准 $X_2 = 0$ 时 $X_2 = 1$ 的情况
会使 y 加 β_2

② 1 个 k 种取值变量, eg. 地区销量 X_3
k-1 个哑变量 $H_0: \mu_A = \mu_B = \mu_C$
 $X_1 = \begin{cases} 1, B \\ 0, \text{其他} \end{cases} E(y|A) = \beta_0$
 $X_2 = \begin{cases} 1, C \\ 0, \text{其他} \end{cases} E(y|B) = \beta_0 + \beta_1$
 $E(y|C) = \beta_0 + \beta_2$
 $y = \beta_0 + \beta_1 X_1 + \beta_2 X_2 + \epsilon$ B & C 相对于 A 基准
11. Chow Test $\Rightarrow$ 回归方程变化
 $y = \beta_0 + \beta_1 X_1 + \beta_2 X_2 + \beta_3 X_3 + \epsilon$ 在单行
STEP1: 对线性回归 $\Rightarrow SSE_1$
STEP2: 单行一起 $\Rightarrow SSE_p$
 $F = \frac{[SSE_p - (SSE_1 + SSE_2)] / (p+1)}{(SSE_1 + SSE_2) / (n - 2(p+1))}$ 与 F_{α} 比较
 $\sim F(p+1, n-2(p+1))$ 与 F_{α} 比较
前提: 组内误差相等

12. 线性分析 $\epsilon \sim N(0, \sigma^2)$
线性化处理: 求 S_{ij}^2
 $S_{ij}^2 = \frac{\sum y_i}{S_{y_i} - \bar{y}_i} = \frac{y_i - \bar{y}_i}{S_{y_i} - \bar{y}_i} \sim N(0, 1)$
 $\Rightarrow$ 画图: 是否存在 [2, 2] 内 3 个法则