

基于回归模型的结直肠癌风险预测分析

1. 数据清洗与预处理


在数据清洗阶段，针对不同类型的数据采取了不同的处理策略，以确保数据的质量和可靠性。

(1) 连续变量 (X1-X43) 的处理

- 缺失值**：对于连续变量 X1-X43，观察到缺失值较少，所以采用均值填充的方法对缺失值进行填补。这种方法能够在一定程度上保留数据的统计特性，同时避免过多地信息损失。（train数据&test数据）
- 异常值**：在处理X1-X43中异常值时，采取了谨慎的态度。医学数据中的异常值可能具有重要的病理学意义，因此不能简单地将其视为错误数据而直接删除。某些生理指标在正常范围内可能呈现一定的波动，但超出正常生理范围的极端值可能属于记录错误。通过这种方式识别并去除了明显不符合人类生理情况的错误数据，同时保留了可能因病理原因导致的异常值，以确保数据的完整性和准确性（只对train数据）。

对每个连续变量绘制了直方图，观察其分布情况，并结合医学知识和数据的实际背景，为每个变量设置了合理的上下限。

例如，以 X5（葡萄糖）这一指标为例，根据医学知识，其正常生理范围通常为 3.9-6.1 mmol/L。而从训练数据而来的直方图可见，X5 的值主要集中在 3.0-6.0 mmol/L 的范围内，这与正常生理范围较为一致。然而，存在一些极端值（如 30.0、56.0 和 60.0 mmol/L），这些值明显超出了正常生理范围。在查阅医学文献发现，随机血糖（任意时间测量）超过17.8mmol/L时，会发生糖尿病急性并发症，可能出现脱水、意识模糊、昏迷等症状，如此高的数值在正常生理情况下较少见，因此被认定为可能的记录错误。为了确保数据的准确性和可靠性，对 X5 的上限进行了设定：将高于 28.0 mmol/L（包含28）的值视为异常值并进行处理。



- 标准化**：对连续变量进行标准化，消除不同特征量纲和数量级差异对模型的影响。
- 多重共线性问题的处理**：在对数据进行初步分析后，发现部分变量之间存在较高的相关性，这可能导致多重共线性问题，影响回归模型的稳定性和解释性。计算了变量之间的相关系数矩阵，并识别出高度线性相关（Correlation>0.85）的变量对，具体如下表所示：

Feature 1	Feature 2	Correlation
X40	X43	0.967928
X33	X34	0.959482
X10	X12	0.912378
X26	X29	0.903690
X35	X36	0.884287
X39	X41	0.882535
X32	X34	0.881372
X32	X33	0.853233

为了下一步对哑变量（X44、X45）的预测，初步处理多重共线性问题，暂时对表格中的变量采用了主成分分析（PCA）降维技术，保留了能够解释 95% 方差的主成分的7个新变量（PC1-PC7）。这些主成分与剩余（不高度线性相关）的变量一起，构成了新的连续变量集合，用于后续的哑变量处理。（train数据和test数据）

(2) 哑变量（X44、X45）的处理

- 缺失值：
 - 从医学角度来看，X44、X45与是否患有结直肠癌具有重要的关联性（粪隐血是国际公认的早期筛查手段，灵敏度86.6%；粪转铁蛋白因稳定性优于血红蛋白，对癌前病变（如腺瘤）的检出率更高；而两者联合检测阳性率可达91.67¹）。对于这两个变量的缺失值，不能简单地按照原数据比例随机生成的 0 或 1 进行填补，因为这可能会引入不必要的噪声，影响模型的预测效果。
 - 为了填补这些缺失值，采用**基于其他变量的预测方法**。具体而言，在对 X1-X43 进行 数据清洗及PCA 降维处理后，提取出主要的特征信息。然后，以这些降维后的特征作为自变量，以 X44 和 X45 中的另一个变量作为因变量，构建逻辑回归模型。在模型训练过程中，剔除了不显著的变量（p 值大于 0.05 的变量），以确保模型的稳定性和解释性。通过这种方法，对缺失的哑变量（train数据&test数据）进行较为准确的预测。
 - 需要注意的是，**在预测过程中，没有将因变量 Y 纳入模型**。这是因为 Y 本身是回归模型的输出，将其纳入预测范围可能会引入因果关系混淆，导致模型解释性变差。此外，如果将 Y 纳入模型，可能会产生循环推理的问题，从而引入偏差。因此，在预测哑变量时，仅使用了其他相关的自变量，以确保模型的科学性和合理性。

(3) 其他处理

(1) 数据不对称：在训练数据中，未患病个体（ $y=0$ ）的数量明显多于患病个体（ $y=1$ ）的数量。这种数据不平衡可能会影响模型的训练效果，导致模型对多数类（未患病）的预测更为准确，而对少数类（患病）的预测能力较弱。为了平衡数据，采用了 SMOTE方法。

- 在少数类样本（ $y=1$ ）之间插入新的合成样本来增加少数类的样本数量，使得 $y=1$ 的样本数量与 $y=0$ 的样本数量一致。这样可以有效缓解数据不平衡问题，提高模型对少数类的预测能力。

(2) 构建正常值范围

为使数据更适合回归模型的训练，模拟人类医生在判断患者是否生病时的思维方式，对数据进行了特殊的处理。医生通常会根据各项指标是否超出正常范围、偏高还是偏低以及超出的程度来判断患者的健康状况。因此，对数据的处理方式也借鉴了这一思路，具体步骤如下：

项目名称	结果	单位	参考区间	项目名称	结果	单位	参考区间
1 ★白细胞	4.70	10 ⁹ /L	3.5-9.5	16 血小板平均体积	9.2	fL	7.4-10.1
2 淋巴细胞百分比	24.7	%	20.0-50.0	17 大血小板比率	19.6	%	13.0-43.0
3 单核细胞百分比	6.0	%	3.0-10.0	18 血小板分布宽度	9.7	fL	9.0-18.0
4 中性粒细胞百分比	68.7	%	40.0-70.0	19 嗜酸细胞百分比	0.4	%	0.0-9.0
5 淋巴细胞绝对值	1.16	10 ⁹ /L	1.10-3.20	20 嗜碱细胞百分比	0.2	%	0.0-1.0
6 单核细胞绝对值	0.28	10 ⁹ /L	0.10-0.60	21 嗜酸细胞绝对值	0.02	10 ⁹ /L	0.02-0.52
7 中性粒细胞绝对值	3.23	10 ⁹ /L	1.80-6.30	22 嗜碱细胞绝对值	0.01	10 ⁹ /L	0.00-0.06
8 ★红细胞	3.57	↓ 10 ¹² /L	3.80-5.10	23 红细胞分布宽度SD	45.8	fL	37.0-54.0
9 ★血红蛋白	73	↓ g/L	115-150	24 血小板比积	0.27	%	0.10-0.50
10 ★红细胞压积	25.6	↓ %	35.0-45.0	25 网织血小板比率	2.10	%	0.8-6.3
11 ★平均红细胞体积	71.7	↓ fL	82.0-	26 网织红细胞百分比	2.1	↑ %	0.5-1.5
12 ★平均RBC血红蛋白量	20.4	↓ pg	27.0-34.0	27 网织红细胞绝对值	76.00	*10 ⁹ /L	36.3-
13 ★平均RBC血红蛋白浓度	285	↓ g/L	316-354	28 幼稚网织红细胞比率	18.4	↑ %	3.9-13.4
14 红细胞分布宽度CV	17.6	↑ %	11.5-14.5	29 网织红细胞血红蛋白含量	18.0	↓ pg	32.1-38.8
15 ★血小板计数	320	10 ⁹ /L	125-350				

从训练数据中提取未患病个体（y=0）的数据，针对除哑变量 X44、X45 之外的每个变量（PCA 降维后共 37 个变量），构建正常值范围。采用 10 分位数到 90 分位数作为正常范围的上下限，这种方法能够有效避免健康个体极端值对正常范围的过度影响，同时涵盖大部分健康个体的特征分布。

选择 10 分位数和 90 分位数的理由：处于对稳健性考虑：使用 10 分位数和 90 分位数作为正常范围的上下限，而不是极端的最小值和最大值，是为了避免极端值对正常范围的过度影响。这种方法能够更稳健地反映数据的中心趋势，同时排除可能的异常值或记录错误。

从数据中构建正常范围而非直接用医学定义的理由：

- **数据偏差：**需要注意的是，这些数据的选择是有偏差的。样本并非随机抽取的健康人群，而是主动去体检或看病的人群。这类人群可能已经存在某些健康问题或风险因素，因此其数据分布可能与一般健康人群不同。直接使用医学定义的正常范围可能不适用于这些特定的样本。
- **针对特定疾病：**对于结直肠癌这类疾病，直接从数据中构建正常范围可能更为合适。因为这些数据反映了实际就诊人群的特征分布，能够更好地捕捉与结直肠癌相关的异常情况。医学定义的正常范围通常是基于一般健康人群的统计结果，可能无法完全适应本研究中特定的样本特征。
- **数据驱动的方法：**通过从数据中构建正常范围，可以确保正常范围的定义与实际样本的特征一致，从而提高模型的准确性和可靠性。这种方法能够更好地反映样本的真实情况，避免因使用不完全匹配的正常范围而导致的误判。

(3) 特征工程：对每个变量进行以下特征工程处理，以量化特征值与正常范围的关系：

- **标准化偏离：**计算特征值与正常范围均值的差，然后除以标准差。
 - 目的：衡量特征值与正常范围中心点的相对距离，通过标准差进行标准化。结果是一个无量纲的指标，表示特征值距离均值多少个标准差。
- **范围偏离：**二元变量（取值为 0 或 1），如果特征值在正常范围内，该指标为 0；如果特征值超出该范围，该指标为 1。
 - 目的：识别那些落在正常范围之外的值，为模型提供是否异常的直接信息。

- 低于下限的偏离：计算特征值低于正常范围最小值时的偏离程度，如果特征值小于最小值，偏离程度为最小值与特征值的差；如果特征值大于或等于最小值，偏离程度为 0。

$$\text{低于下限的偏离} = \max(0, \text{最小值} - \text{特征值}) \quad (1)$$

- 目的：量化低于正常范围下限的偏离程度，为模型提供偏离方向和程度的信息。

- 高于上限的偏离：计算特征值高于正常范围最大值时的偏离程度，如果特征值大于最大值，偏离程度为特征值与最大值的差；如果特征值小于或等于最大值，偏离程度为 0。

$$\text{高于上限的偏离} = \max(0, \text{特征值} - \text{最大值}) \quad (2)$$

- 目的：量化高于正常范围上限的偏离程度，为模型提供偏离方向和程度的信息。

(4) 多重共线性问题的处理：对所有数据进行 PCA（主成分分析），对特征进行了降维处理，保留了能够解释 95% 方差的主成分。

这步操作可能会有点多余，但是为了让后续的 logistic gam 模型跑得更快，所以我进行了 PCA 降维操作，如果有足够的时间以及电脑性能，可以省略。

2. 回归模型构建

(1) 回归模型选择

在本研究中，选择了 **Logistic GAM（广义可加模型）回归** 作为主要的预测模型。这一选择基于以下考虑：

- **模型灵活性**：Logistic GAM 回归结合了逻辑回归的分类能力和广义可加模型的灵活性，能够有效处理非线性关系和复杂的特征交互。
- **特征降维**：在特征工程阶段，通过 PCA（主成分分析）对特征进行了降维处理，保留了能够解释 95% 方差的主成分。这不仅减少了特征的数量，提高了模型的训练效率，还避免了多重共线性问题，增强了模型的稳定性和解释性。
- **模型解释性**：Logistic GAM 回归在保持较高预测性能的同时，能够提供对特征重要性和影响方向的直观解释，这对于医学领域的应用尤为重要。

(2) Logistic GAM（广义可加模型）回归原理

Logistic GAM 回归 是一种结合了逻辑回归和广义可加模型的统计方法，特别适用于处理复杂的非线性关系和特征交互。其核心思想是将响应变量的预测值表示为多个特征函数的加权和，每个特征函数可以是非线性的，从而捕捉特征与响应变量之间的复杂关系。

具体来说，Logistic GAM 回归模型可以表示为：

$$\log\left(\frac{p}{1-p}\right) = \beta_0 + f_1(x_1) + f_2(x_2) + \cdots + f_p(x_p) \quad (3)$$

- p 是响应变量为 1 的概率。
- β_0 是截距项。
- $f_i(x_i)$ 是第 i 个特征 x_i 的非线性函数。
- $x_1, x_2, \dots, x_p$ 是特征变量。

特征处理：

- **连续变量：**对于连续变量，使用**三次自然样条**进行建模。三次样条是一种分段三次多项式函数，能够在保持平滑性的同时捕捉非线性关系。每个连续变量的样条数量 n 被设置为 5 到 10，具体数量通过网格搜索（Grid Search）进行优化。
- **二元变量：**对于二元变量（0/1），直接使用哑变量进行处理，确保模型能够准确处理分类特征。

模型训练：

- Logistic GAM 回归通过最大化似然函数来估计模型参数，同时利用样条函数的平滑性来控制模型的复杂度，避免过拟合。
- **网格搜索：**使用网格搜索方法对模型的惩罚参数进行优化，确保模型在训练数据上具有最佳性能。
- 最后预测得到的每个p值，大于0.52的判断为1（患病），小于0.52的判断为0（正常）。

模型优势：

- **非线性建模：**能够捕捉特征与响应变量之间的非线性关系，提高模型的预测能力。
- **特征交互：**可以自然地处理特征之间的交互作用，而无需手动构造交互项。
- **模型解释性：**通过样条函数的可视化，可以直观地理解每个特征对响应变量的影响方向和程度。

模型结果：通过1中的数据预处理与Logistic GAM 回归模型，成功地对结直肠癌的风险进行了预测。模型在训练数据上的表现非常出色，能够很好地捕捉特征与响应变量之间的非线性关系。在 Kaggle 平台上提交的预测结果取得了0.8 以上的F1 分数，这表明模型在预测结直肠癌风险方面具有较高的准确性和可靠性，能够为高风险群体提供及时的干预建议。

3. 模型对比与分析

除了主要的 Logistic GAM 回归模型外，还尝试了多种不同的模型、数据处理方式、阈值以及上述三种情况的各种排列组合情况，以评估它们对预测结直肠癌风险的影响。以下是详细的对比分析：

(1) 尝试只从医学背景选取变量，构建模型。

- 与结直肠癌高度相关的变量：
 - 癌胚抗原（CEA, X8）²：CEA是结直肠癌最经典的肿瘤标志物，约70%-80%患者血清水平升高，尤其在肝转移时显著升高。术前CEA水平与肿瘤分期正相关，术后持续升高提示复发风险。
 - 糖类抗原CA199（X9）²：CA199单独敏感度较低（约35%），但与CEA联合检测可提升敏感度至90%。其水平升高与淋巴结转移、肝转移及预后不良显著相关。
 - 粪隐血（X44）与粪转铁蛋白（X45）¹：粪隐血是国际公认的早期筛查手段，灵敏度86.6%；粪转铁蛋白因稳定性优于血红蛋白，对癌前病变（如腺瘤）的检出率更高。两者联合检测阳性率可达91.67%，显著优于单一检测。
 - 肝功能指标（X10-X12, X22-X23）³：总胆红素（X10）、丙氨酸氨基转移酶（ALT, X22）与CEA联合可预测癌症肝转移（AUC=0.921）。而白蛋白-胆红素评分（ALBI）是独立预测因子。这些指标不直接与原发结直肠癌相关，而是与结直肠癌有着间接关联，可以反映肝转移或肿瘤负荷。
 - 免疫细胞指标⁴：白细胞计数（X26）、中性粒细胞计数（X29）升高代表着炎症反应，与肿瘤侵袭性相关，提示预后不良。


- 血小板参数⁵：血小板计数（X38）、血小板计数（X39）、平均血小板体积（X40）升高与癌症转移风险相关。

- 与结直肠癌弱相关或不相关的变量

- 电解质（X1-X3：钾、钠、氯）⁶：钾可能与癌细胞侵袭相关（动物研究），但临床数据不足；钠、氯未见明确关联。
- 肾功能指标（X6-X7：肌酐、尿素）：具有非特异性，可能反映全身代谢状态，但与结直肠癌无直接病理关联。
- 总蛋白/白蛋白/球蛋白（X13-X15）³：作为营养状态标志，低白蛋白可能提示恶病质，但缺乏特异性。
- 尿酸（X25）与二氧化碳结合力（X24）：无显著关联。

- 可能存在多重共线性的变量组合

- 胆红素系列⁷：存在数学关联。总胆红素（X10）= 直接胆红素（X11）+ 间接胆红素（X12），存在严格数学依赖。



- 红细胞参数：红细胞计数（X33）、血红蛋白（X34）、红细胞比积（X35）、平均红细胞体积（X35）常呈共线性，反映同一生理维度。
- 血小板指标⁵：几个指标参数互依，血小板计数（X38）、平均体积（X39）、分布宽度（X40）、压积（X41）存在内在关联。
- 肝功能酶类³：ALT（X22）、AST（X23）、碱性磷酸酶（X24）、γ-GT（X25）常在肝损伤时同步升高，具有协同变化，导致共线性。

综上所述，建模时选择特异性强的指标（如X8、X9、X44、X45等），并对于存在多重共线性的特异性强变量采取只取其中一个变量的操作，然后进行模型回归。然而单纯从医学角度出发进行变量选择以及模型回归的结果不太理想，F1 Score只有0.67~0.72左右。

（2）使用2中同样的数据预处理的方法，但使用不同的模型：

- 单纯的 Logistic 回归：使用 Logistic 回归模型进行建模。模型的 F1 分数约为 0.77，表现一般。
- 单纯的 GAM 模型：使用广义可加模型（GAM）进行建模。模型的 F1 分数约为 0.78，优于单纯的 Logistic 回归。
- 多元线性回归模型：使用多元线性回归模型进行建模。模型的 F1 分数约为 0.76，表现较差。
- Lasso 和 Ridge 回归：分别使用 Lasso 和 Ridge 回归进行建模。Lasso 回归的 F1 分数约为 0.76，Ridge 回归的 F1 分数约为 0.77~0.78，表现中等。

- 随机森林+XGBoost 模型：使用随机森林模型进行建模。模型的 F1 分数约为 0.81作用，表现好，但是属于超纲内容不得使用。

(3) 尝试采用不同的数据处理方式：

- 完全不采用特征工程的方式：直接使用原始特征进行建模，不进行任何特征工程。不论用哪个回归模型 F1 分数表现都会稍差。
- 异常值进行 3 倍标准差外删除的处理：删除超过 3 倍标准差的异常值。模型的 F1 分数下降很多，因此我才得出对“医学的异常”是有意义的思考。
- 尝试不用 PCA 处理：不进行 PCA 降维处理，直接使用所有特征进行建模，在不同模型中，F1分数的表现不一，有的变高有的反而变低。

(4) 尝试对 Logistic 回归得到的 (p) 的阈值进行不同的尝试：

对于Logistic回归以及 Logistic GAM 回归，调整预测概率 (p) 的阈值，从 0.4 到 0.6 进行尝试，发现当阈值设置为 0.52 时，即大于0.52，y=1（患病）；小于0.52，y=0（健康），此时模型的 F1 分数最高。


(5) 对不同数据处理方式、不同模型、不同阈值进行排列组合情况

虽然可能没有穷尽所有情况，但是经过我的多次尝试（提交了100多次predictions阿喂!!!），对不同数据处理方式、不同模型以及不同阈值进行了混合对比。最终发现，结合特征工程（如 PCA 降维、“错误非异常值”的处理等）和 Logistic GAM 回归模型，并适当调整阈值，模型的 F1 分数在 Kaggle 平台上达到了 0.8 以上，显著优于其他组合。

4. 特征分析与筛选

(1) 关键影响变量识别

- 从图表分析：下图展示了当 y=1（即患者患病）时，各个变量不在正常范围的人数比例。通过分析图表，我们可以识别出与结直肠癌高度相关的变量。这些变量在患者中显示出异常的比例较高，表明它们可能对疾病有较强的指示作用。高度相关的变量：粪隐血（X44）和粪转铁蛋白（X45）的比例特别高，分别接近 0.8 和 0.7；而后一些血液学指标，如平均红细胞体积（X35）平均红细胞血红蛋白含量（X36）、红细胞分布宽度（X38）也比例较高，在0.5左右。这表明这些变量可能在识别结直肠癌患者时比较重要。



- 从医学角度来看，以下变量也与结直肠癌高度相关（先前已论述），也从图表中发现这几个指标比例较高：

- 癌胚抗原（CEA, X8）：是结直肠癌最经典的肿瘤标志物。
- 粪隐血（X44）与粪转铁蛋白（X45）：是国际公认的早期筛查手段。
- 肝功能指标（X22-X23）：与结直肠癌有着间接关联。
- 血液学参数：红细胞相关（X35-X36）、血小板计数（X38）、平均血小板体积（X39）与癌症转移风险相关。
- 在构建预测模型时，不仅要考虑医学上的专业知识，还要结合数据驱动的方法来识别关键变量。因此采用L1正则化Lasso回归（通过引入L1惩罚项，促使模型自动进行特征选择，将不重要的特征系数压缩至零，从而实现降维和特征选择，同时通过对系数的绝对值进行排序来决定特征重要性）来识别在统计上显著且可能在临床上有重要意义的变量，从而更准确地预测结直肠癌风险。
 - 最佳正则化参数（ α ）：在模型训练过程中，我们通过网格搜索找到了最佳的正则化参数 α ，其值为0.00046415888336，决定了惩罚项的强度，进而影响特征选择的结果。
 - 显著变量（系数非零的变量）：X1, X2, X3, X5, X6, X7, X8, X9, X10, X12, X13, X14, X15, X17, X18, X19, X20, X21, X22, X23, X24, X25, X27, X28, X29, X30, X31, X32, X33, X34, X35, X37, X38, X39, X40, X41, X42, X43, X44, X45
 - 非显著变量（系数被压缩为零的变量）：X4, X11, X16, X36

排序	变量	系数	排序	变量	系数	排序	变量	系数
1	X44	0.188871	14	X14	-0.024592	27	X29	-0.009133
2	X38	0.098788	15	X30	0.020622	28	X34	-0.00871
3	X43	-0.077264	16	X2	-0.01983	29	X31	-0.007538
4	X40	0.049429	17	X39	-0.018361	30	X33	-0.00871
5	X12	0.044511	18	X37	0.016747	31	X23	0.007714
6	X13	0.043707	19	X20	-0.016063	32	X24	0.007714
7	X22	-0.042624	20	X8	0.016055	33	X25	-0.000127
8	X35	0.042154	21	X28	0.015732	34	X26	0
9	X15	-0.039975	22	X7	-0.013442	35	X36	0
10	X10	-0.037562	23	X45	0.011046	36	X16	0
11	X1	0.029681	24	X17	0.010746	37	X11	0
12	X33	-0.026661	25	X3	-0.010321	38	X4	0
13	X27	-0.026564	26	X19	0.010226			

- 而根据系数的绝对值排序可以观察到几个关键影响变量：X44, X38, X43, X40, X12, X13, X22, X35, X15, X10。这些变量在模型中显示出较大的系数绝对值，表明它们对预测结果具有显著的影响。这与我们之前的预期既有重叠之处，又稍微有所不同：
 - X44与X38在本排序中与之前预测的同样重要。
 - 原本认为非常重要的癌胚抗原（X8）以及粪转铁蛋白（X45）在模型中并没有显示出显著的影响。
 - 一些先前未被特别注意的变量在Lasso正则化过程中表现出了显著性，例如总胆红素（X10）、间接胆红素（X11）以及大血小板细胞比率（X43）和平均血小板体积（X40），代表着可能需要重新评估这些变量在结直肠癌诊断中的潜在作用。

- 从纯医学角度来看属于弱相关的变量，如总蛋白（X13）以及球蛋白(X15)，在先前研究中被认为特异性不够，然而在当前数据集中却与结直肠癌显示出十分强烈的关联性。这可能代表着新的研究方向，也可能是数据集特有的问题。

(2) 冗余或低贡献变量以及处理前后对比

通过计算特征之间的相关系数矩阵，我们识别了一些高度相关的特征对，在1中数据处理部分已经出现过，这些特征可能出现重复冗余，存在着多重共线性，需要进行处理以避免模型复杂度过高和过拟合的风险。

- PCA降维处理：通过正交变换将原始特征转换为一组新的特征。这些主成分特征按照方差大小排序，能够捕捉数据中的主要变异性。选择前几个主成分，保留95%的方差，去除那些对数据变异贡献较小的特征，从而减少冗余变量，简化模型。
 - 结果：应用PCA后，不管运用哪个线性模型，F1分数都有所提高。这是因为PCA去除了对模型贡献较小的特征，减少了模型的复杂度，降低了过拟合的风险。降维后的特征保留了数据中大部分信息，同时减少了噪声和冗余变量的影响，使得模型更加专注于那些对预测目标变量最有用的特征。
- Logistic GAM回归：通过结合了逻辑回归和广义可加性模型的优点，能够处理特征之间的非线性关系和交互作用。GAM允许每个特征通过一个平滑函数与响应变量相关，而不是简单的线性关系。
 - 结果：使用Logistic GAM回归后，比起单纯GAM模型以及单纯logistic模型，F1分数进一步提高。这是因为Logistic GAM回归不仅能够处理特征的非线性关系，还能够自动选择重要的特征并忽略不重要的特征，从而减少模型中的冗余变量，提高模型的预测准确性和泛化能力，使得模型在新的数据上的表现更加稳定和可靠。
- 基于统计显著性的特征删除：在模型构建过程中（如logistic回归模型），删除统计显著性 p 值大于 0.05 的特征。通过移除不显著的特征，可以简化模型，减少噪声的影响，并可能降低过拟合的风险。
 - 结果：F1 Score在某些情况下更好了，而在另外一些情况下更差了，这可能是因为
 - 丢失重要信息：某些特征在统计上不显著，但对模型预测能力有重要影响，失去了一些有价值的信息而预测能力降低。。
 - 模型性能影响：删除这些特征可能导致模型性能下降，因为它们可能在模型中起到平衡其他特征的作用。
 - 替代方法（暂未尝试）
 - 基于模型的特征选择：使用模型（如随机森林、梯度提升树）内建的特征重要性评估来选择特征，从而识别出对模型预测性能贡献最大的特征，而不考虑它们的统计显著性。但是由于模型超出课程内容，所以还未尝试。
 - 逐步选择回归：逐步回归通过逐步添加或删除特征来构建模型，每次添加或删除基于统计显著性或其他性能指标，使得在保留模型性能的同时，减少特征的数量。但是由于变量过多运行过慢，所以还未尝试。
 - 交叉验证：使用交叉验证来评估不同特征子集的模型性能，从而识别出在不同数据子集上都表现最优的特征组合，从而提高模型的泛化能力。

5. 医学问题中的模型性能考量

(1) 误诊代价的医学影响分析

- **假阳性 (False Positive, FP)**：即健康的人被判断为患病，即 ($P(y=1 | y=0)$)。
 - 代价分析：
 - 心理焦虑：短期会给误诊的患者带来一些心理压力。
 - 医疗资源消耗：患者可能会选择进行进一步的检测来确认是否真的患病，会造成医疗资源的消耗。
 - 潜在优势：假设初次假阳性概率 $P(y=1 | y=0)=P_{FP}^{(1)}$ ，而再次检测被误判为患病的概率为 $P_{FP}^{(2)}$ ，则连续误诊概率：

$$P_{\text{连续FP}} = P_{FP}^{(1)} \times P_{FP}^{(2)} \quad (4)$$

由于 $P_{FP}^{(1)}$ 和 $P_{FP}^{(2)}$ 通常较小，因此连续误诊的概率较低。患者在经过进一步检测后，大概率会发现自己是健康的，只是损失了一些时间和金钱。相比之下，这已经算是较为幸运的情况。

- **假阴性 (False Negative, FN)**：即患病的人被判断为健康，即 ($P(y=0 | y=1)$)。
 - 代价分析：
 - 病情加重：被诊断为健康的患者往往会安心松懈，误以为自己健康而不做第二次检测，导致病情恶化，给身体带来更大的伤害。
 - 延误治疗：患者可能会错过最佳治疗时机，增加治疗难度和成本，甚至可能危及生命，结如直肠癌早期5年生存率90%，而晚期的5年生存率仅有14%。

(2) 阈值选择策略与性能指标优化方法

由 (1) 中分析可见，在结直肠癌风险预测中，假阴性的代价远高于假阳性。因此，在选择模型阈值时，需要更倾向于减少假阴性，即使这可能会增加假阳性的数量，正所谓“不怕一万，就怕万一”。以下是具体的策略和优化方法：

- **调整阈值选择**：由于假阴性的代价较高，所以最好将模型的阈值设置得比 0.5 更低。例如，可以将阈值设置为 0.45 或更低，以减少假阴性的数量。当预测概率 p 接近 0.5 的时候，模型本身也比较不确定患者是否真的患病。在这种情况下，出于稳健的考虑，倾向于判断患者为患病（即降低阈值），这样可以有效减少因漏诊而导致的严重后果和代价。

虽然这可能会增加一些假阳性的数量，但从稳健地角度出发，考虑到假阴性的高代价和对病人的负责，这种权衡是合理的。通过降低阈值，模型能够在不确定的情况下更倾向于保守的判断，从而更好地保护患者的健康。

- **性能指标优化**：
 - **召回率**：虽然 F1 分数是一个同等权重下综合考虑精确率和召回率的指标，但在结直肠癌风险预测中，更应关注召回率，即关心假阴性的减少。因此，在优化模型时，可以适当牺牲一些精确率，以提高召回率。

$$\text{召回率} = \frac{\text{真阳性 (TP)}}{\text{真阳性 (TP)} + \text{假阴性 (FN)}} \quad (5)$$

- **特异度**：虽然特异度在结直肠癌风险预测中不是首要目标，但仍需控制在合理范围内，以避免过度医疗。可以通过预估值校准（如 Platt Scaling）来调整模型的输出概率，确保模型在提高召回率的同时，不会过度增加假阳性的数量。

$$\text{特异度} = \frac{\text{真阴性 (TN)}}{\text{真阴性 (TN)} + \text{假阳性 (FP)}} \tag{6}$$

- **ROC 曲线和 AUC**：通过绘制 ROC 曲线和计算 AUC 值，可以评估模型在不同阈值下的性能。ROC 曲线展示了模型在不同阈值下的真阳性率（召回率）和假阳性率（1 - 特异度）的关系，AUC 值则表示模型的整体性能。
选择一个合适的阈值，使得模型在减少假阴性的同时，尽量控制假阳性的数量。可以通过 ROC 曲线找到一个平衡点，使得模型在提高召回率的同时，不会显著降低特异度。
- **代价敏感学习**：一种在模型训练过程中考虑不同错误类型的代价差异的方法。通过为假阴性赋予更高的代价权重，可以优化模型的性能，使其更倾向于减少假阴性，从而提高模型的整体性能。
- 假阳性和假阴性之间找到一个合理的平衡点，确保模型在结直肠癌风险预测中具有较高的准确性和可靠性。

6. 模型评估与优化

过拟合 / 欠拟合现象判断

在模型评估过程中，通过对训练集（train data）进行 10 折交叉验证，将训练集划分为 10 个子集，每次使用 9 个子集进行训练，剩下的 1 个子集进行验证，重复 10 次，取平均性能作为模型的评估结果。此外，对独立的测试集（test data）从Kaggle 得到最终的F1 score。

指标	训练集（10 折交叉验证）	测试集（10 折交叉验证）	测试集（独立测试集）
准确率	0.8284	0.8150	/
精确率	0.8432	0.8200	/
召回率	0.8069	0.7800	/
F1 分数	0.8247	0.8120	0.81

- 训练集（10 折交叉验证）的 F1 分数为 0.8247，而测试集（10 折交叉验证）的 F1 分数为 0.8120，测试集（独立测试集）的F1分数是0.81左右，差距都不大。
- 训练集（10 折交叉验证）的准确率、精确率以及召回率与测试集（10 折交叉验证）的区别都在0.01-0.027 间，差距不大。
- 虽然模型在训练集上的性能略好于测试集，但整体差距较小，这表明模型没有明显的过拟合现象。

7. 未来数据收集建议

(1) 现有数据局限性分析

- 特征覆盖不全面：

- 范围局限：当前数据集中的特征主要集中在血液指标和一些基本的生理指标，缺乏一些可能对结直肠癌诊断有重要意义的其他特征。例如，年龄、家族病史、生活方式（如饮食习惯、运动频率、是否熬夜等）、环境（是否接触甲醛环境等！这个很重要因为我姐就是因为长期在家具店工作所以得了急性白血病！）因素等同样重要的变量未被纳入数据集的采集中。这些因素可能对结直肠癌的患病判断有显著影响。
- 时间维度缺失：当前数据集缺乏时间维度的信息，无法记录不同指标在时间上的变化情况。这种缺失使得我们难以观察到疾病的发展趋势，也无法评估模型在不同时间点的预测效果。
- 样本数据分布偏差：当前数据集中的样本主要是主动去体检或看病的人群，可能存在一定的选择偏差。这些样本可能已经存在某些健康问题或风险因素，导致数据分布与一般健康人群不同，所以在数据处理中，出于稳健性的考量，正常范围的构建是通过10分位数到90分位数，但这种方法可能不完全准确。这种偏差会影响模型的泛化能力，使其在预测一般健康人群时表现不佳。
- 模型简略：只使用上课所学到的模型，并未涉及更高阶的机器学习、神经网络等模型，可能模型预测能力较差。

(2) 优化数据收集的方向与方法

- 特征扩充：
 - 增加临床特征：补充与结直肠癌相关的临床特征，如年龄、家族病史、生活方式、环境因素等。这些特征可以提供更全面的患者信息，有助于提高模型的预测能力。
 - 引入panel data：对患者进行长期随访，收集他们在不同时间点的健康数据构建面板数据。这将有助于观察疾病的发展趋势，评估模型在不同时间点的预测效果。
- 样本随机收集：
 - 扩大样本来源：通过与更多的医疗机构合作，收集来自不同地区、不同年龄、不同性别的人群数据，以减少样本的选择偏差，从而能够在更无偏的样本基础上重新构建正常范围，以提高模型的准确性和泛化能力。
 - 增加患病人群样本：除了收集健康人群样本，还应增加患病人群的样本数量，以确保数据集不出现不平衡的问题。
- 使用高阶模型：如深度学习、神经网络、Transformer架构等，加强模型等预测能力。

我在做的一个prp项目（用大语言模型来对上市公司财报进行文本分析）启发了我，虽然我不会自己训练一个大语言模型，但是我想是不是可以借助现有的模型进行训练预测。比如最简单的deepseek本地部署，或者使用专门的医学模型，通过对现有的数据进行学习，然后对新的结果进行预测。我尝试写了个代码然后跑了一下，是可以预测出结果的，但是由于需要的token可能比较多，所以我仅停留在测试了几个上面。后续可以给deepseek更多的prompt提示、更多token以及更多时间来预测。

```
使用的 API 密钥: sk-e601ab067e9b4d4c83f7d212e51c1898
返回结果: 1
返回结果: 0
返回结果: 0
返回结果: 1
返回结果: 0
返回结果: 1
返回结果: 0
返回结果: 1
```

8. 案例诊断与建议

(1) 运用回归模型对第 6、7 位患者的预测结果以及数据分析：

- 第 6 位患者：预测结果为未患病 ($y=0$)，然而根据他的各项指标可以发现：
 - 异常：X44 粪隐血、X45 转铁蛋白
 - 异常高：X13 总胆汁酸、X32 红细胞计数、X33 血红蛋白、X34 红细胞比积
 - 异常低：X28 γ -谷氨酰转肽酶
- 第 7 位患者：预测结果为未患病 ($y=0$)，然而根据他的各项指标可以发现：
 - 异常高：X20 门冬氨酸氨基转移酶、X39 血小板分布宽度、X41 大血小板细胞比率
 - 异常低：X19 丙氨酸氨基转移酶、X30 血小板计数、X41 大血小板细胞比率

(2) 针对患者的健康管理建议

- 第六位患者：
 - 粪便隐血 + 转铁蛋白阳性：消化道出血
 - 上消化道（胃、十二指肠）：**胃或十二指肠黏膜破损**、溃疡等导致血管破裂出血，血液经胃酸作用后红细胞破坏，随粪便排出，使粪隐血和转铁蛋白检测呈阳性。
 - 下消化道（结肠）：**结直肠息肉、肿瘤表面糜烂或炎症（如溃疡性结肠炎）**引起出血，血液混入粪便，出现隐血阳性，但鲜血便相对少见。
 - 红细胞增多（Hb、HCT、MCV 升高）
 - 骨髓增殖性疾病：**真性红细胞增多症**可能性大，因骨髓造血干细胞异常增殖，大量生成红细胞，致使血红蛋白、红细胞比积升高；红细胞生成过快，细胞成熟受影响，出现平均红细胞体积升高，需通过 JAK2 V617F 基因突变检测、骨髓穿刺确诊。
 - 血液浓缩：若患者因呕吐、腹泻而引起脱水，MCV 可能因细胞轻度肿胀而升高。**但其他指标（如电解质）正常，提示脱水可能性低。**
 - 肝功能异常（GGT 升高、TBA 降低）
 - GGT 升高：肝胆疾病特异性指标，尤其是**胆道梗阻或肝内胆汁淤积（如胆结石、胆管炎、胆管癌）**。
 - 酒精性肝病：若患者有饮酒史，需考虑酒精性肝病。**但其他肝酶（ALT、AST）正常，不符合典型肝炎表现，排除。**
 - 不符合结直肠癌的部分
 - 血液学表现不符：结直肠癌慢性失血多导致小细胞低色素性贫血（MCV 降低），而患者平均红细胞体积（MCV）异常升高，与缺铁性贫血表现不符。
 - 癌症标志物正常：癌胚抗原（CEA）、糖类抗原 CA199 等肿瘤标志物正常，不支持结直肠癌的肿瘤标记物驱动诊断。
 - 肝功能异常指向性： γ -谷氨酰转肽酶（GGT）显著升高更常见于肝胆系统疾病（如胆道梗阻），而非结直肠癌直接引起。
 - 可能性高的疾病、原因及下一步检查

最可能疾病	原因分析	下一步检查建议
胆道梗阻（如胆总管结石、胆管癌）	γ- 谷氨酰转肽酶（GGT）是胆道梗阻敏感指标；总胆汁酸异常低可能与胆汁排泄受阻有关	腹部超声 /CT/MRI；磁共振胰胆管成像); 胆汁酸谱检测等。
真性红细胞增多症	血红蛋白、红细胞比积、平均红细胞体积升高；无其他导致红细胞增多的继发因素	血清 EPO 水平检测；JAK2 V617F 基因突变检测；骨髓穿刺 + 活检；血常规动态监测。

- 第 7 位患者病情分析：
 - 门冬氨酸氨基转移酶（AST，X20）异常高：肝细胞或心肌细胞损伤
 - 肝细胞损伤：病毒性肝炎、酒精性肝病、药物性肝损伤等导致肝细胞受损，AST 从细胞内释放进入血液，使其水平升高。
 - 心肌细胞损伤：急性心肌梗死等心脏疾病发作时，心肌细胞坏死，AST 释放入血，引起指标异常。
 - 血小板分布宽度（PDW，X39）、大血小板细胞比率（P-LCR，X41）异常高：骨髓造血功能活跃或血小板破坏加速
 - 骨髓造血功能活跃：如原发性血小板增多症早期，骨髓巨核细胞增生，产生大小不均的血小板，导致 PDW 和 P-LCR 升高。
 - 血小板破坏加速：免疫性血小板减少性紫癜（ITP）中，机体免疫系统攻击血小板，骨髓代偿性产生大体积新生血小板，使 PDW 和 P-LCR 升高。
 - 血小板计数（PLT，X30）、大血小板细胞比率（P-LCR，X41）异常低：血小板生成减少或消耗过多
 - 血小板生成减少：再生障碍性贫血、骨髓增生异常综合征等疾病影响骨髓造血干细胞功能，导致血小板生成不足，PLT 和 P-LCR 降低。
 - 血小板消耗过多：弥散性血管内凝血（DIC）时，大量血小板参与凝血过程被消耗，PLT 下降，同时骨髓来不及生成大血小板，P-LCR 降低。
- 不符合结直肠癌的部分
 - 血液学特征不符：结直肠癌常见慢性失血导致缺铁性贫血，表现为小细胞低色素性贫血（平均红细胞体积 MCV 降低、平均红细胞血红蛋白浓度 MCHC 降低），而该患者的红细胞相关指标正常，且血小板异常以计数降低、分布宽度升高等骨髓或免疫因素为主，与结直肠癌的血液学表现无直接关联。
 - 癌症缺乏证据：癌胚抗原（CEA）、糖类抗原 CA19-9 等是结直肠癌常用肿瘤标志物，通常在结直肠癌发生发展过程中会升高，然而此患者癌胚抗原正常；同时患者的粪便隐血与转铁蛋白检测皆为阴性正常，而这两个指标与直结肠癌关系密切。
 - 异常指标指向性差异：患者以 AST 升高、血小板相关指标异常为主，AST 升高更倾向于肝或心肌细胞损伤，血小板异常多与骨髓造血、免疫或凝血功能相关，而结直肠癌通常不会直接引起 AST 显著升高和血小板复杂异常。
- 可能性高的疾病、原因及下一步检查

最可能疾病	原因分析	下一步检查建议
肝细胞损伤 (如病毒性肝炎)	AST 升高为主, ALT 相对正常或轻度异常, 符合肝细胞损伤早期表现, 可能因病毒感染、酒精、药物等因素引发。	肝炎病毒标志物检测; 肝脏超声; 凝血功能; 腹部 CT (排查肝脏病变)。
免疫性血小板减少性紫癜 (ITP)	血小板计数降低, 骨髓代偿性产生大血小板致 PDW 和 P-LCR 升高, 可能因自身免疫紊乱攻击血小板。	血小板抗体检测; 凝血功能; 骨髓穿刺 (观察巨核细胞形态); 血常规动态监测。
急性心肌梗死	AST 升高伴心肌损伤症状 (如胸痛、心悸) 时需考虑, 心肌细胞坏死释放 AST。	肌钙蛋白、肌红蛋白检测; 心电图; 心脏超声 (评估心脏结构和功能)。

9. 医学参考文献

1. 张晓青 李丽 (高邮市中西医结合医院 江苏高邮 225631) 粪便隐血及肿瘤标志物联合检验在诊断结直肠癌中的作用及结果分析 [🔗](#)

2. 中国结直肠肿瘤无创诊断生物标志物应用专家共识 (2023, 北京) 消化健康全国重点实验室 国家消化系统疾病临床医学研究中心 中国医师协会消化医师分会 通信作者: 张澍田, 首都医科大学附属北京友谊医院消化内科 [🔗](#)

3. 白蛋白-胆红素评分联合肝功能指标及CEA对结直肠癌肝转移的预测价值 樊万里、何栋、张树泽、陈刚、赵斌、程志斌 兰州大学第二医院普外科 [🔗](#)

4. Baseline Peripheral Blood Leukocytosis Is Negatively Correlated With T-Cell Infiltration Predicting Worse Outcome in Colorectal Cancers. <https://www.frontiersin.org/journals/immunology/articles/10.3389/fimmu.2018.02354/full> [🔗](#)

5. Circulating basophil count as a prognostic marker of tumor aggressiveness and survival outcomes in colorectal cancer Qi Liu、Dakui Luo、Sanjun Cai、Qingguo Li、Xinxiang Li [🔗](#)

6. 胃癌患者术前血液中钾、钠、氯、镁、磷的相关性及其对生存预后的影响 李旭哲、刘斌正、马雅静、张文杰 [🔗](#)

7. Associations between Prediagnostic Circulating Bilirubin Levels and Risk of Gastrointestinal Cancers in the UK Biobank Nazlisadat Seyed Khoei、Karl-Heinz Wagner、Robert Carreras-Torres、Marc I. Gunter、Neil Murphy and Heinz Freisling [🔗](#)